

**Fundación Universitaria Compensar**  
Programación para Ciencia de Datos II

**Informe de Proyecto Final**

**Actividad 6 Etapa de Transferencia**

Dashboard Interactivo, Análisis de Rotación Laboral

**IBM HR Analytics Employee Attrition Dataset**

**Juan Camilo Rodríguez Fontecha**

Docente: Jeysson Alexander Riaño Pascagaza

27 de marzo de 2026

## Tabla de contenido

|                                                |    |
|------------------------------------------------|----|
| 1. Introducción.....                           | 3  |
| 2. Descripción del Dataset .....               | 3  |
| 3. Evaluación del Rendimiento del Modelo ..... | 4  |
| 3.1 Contraste de Hipótesis.....                | 4  |
| 3.2 Regresión Lineal Múltiple.....             | 5  |
| 3.3 Regresión Logística .....                  | 6  |
| 4. Diseño y Decisiones del Dashboard.....      | 7  |
| 4.1 Estructura y Navegación .....              | 7  |
| 4.2 Tecnologías Utilizadas .....               | 7  |
| 4.3 Componentes Interactivos .....             | 8  |
| 4.4 Decisiones de Diseño Visual.....           | 8  |
| 5. Despliegue: GitHub y Binder .....           | 9  |
| 5.1 Subir el Proyecto a GitHub.....            | 9  |
| 5.2 Obtener el Dashboard en Binder .....       | 9  |
| 6. Conclusiones.....                           | 10 |
| 7. Referencias .....                           | 11 |

## **1. Introducción**

El presente informe corresponde al desarrollo de la actividad final (Etapa de Transferencia) de la asignatura Programación para Ciencia de Datos II. El objetivo es presentar los hallazgos obtenidos a lo largo del curso mediante un dashboard interactivo construido con las bibliotecas Dash y Plotly de Python, tomando como base el trabajo desarrollado en la Actividad de Profundización.

El dataset utilizado es el IBM HR Analytics Employee Attrition & Performance, disponible en Kaggle, que contiene información de 1.470 empleados de una empresa ficticia de IBM con 35 variables. La pregunta de investigación que guía el análisis es: ¿Existen diferencias estadísticamente significativas en el ingreso mensual entre empleados que renuncian y los que permanecen? ¿Es posible predecir la renuncia a partir de variables como ingreso mensual, años en la empresa y trabajo en horas extra?

El informe está organizado en: descripción del problema, evaluación del modelo, decisiones de diseño del dashboard, descripción de los componentes y conclusiones.

## **2. Descripción del Dataset**

El dataset IBM HR Analytics Employee Attrition & Performance contiene 1.470 registros y 35 columnas sin valores nulos. La variable objetivo Attrition presenta una distribución desbalanceada: 83.9% de empleados que permanecen (No = 1.233) y 16.1% que renuncian (Yes = 237). Esta característica motivó el uso de un umbral de

clasificación ajustado (0.30) en la regresión logística para maximizar la sensibilidad del modelo.

**Tabla 1.**

*Variables Principales del Dataset*

| Variable          | Tipo     | Descripción                           |
|-------------------|----------|---------------------------------------|
| Age               | Continua | Edad del empleado en años             |
| MonthlyIncome     | Continua | Ingreso mensual en USD                |
| YearsAtCompany    | Continua | Años en la empresa actual             |
| TotalWorkingYears | Continua | Total, de años de experiencia laboral |
| JobLevel          | Ordinal  | Nivel jerárquico del cargo (1 a 5)    |
| OverTime          | Binaria  | Si trabaja horas extra (Yes / No)     |
| Attrition         | Binaria  | Si abandonó la empresa (Yes / No)     |

### 3. Evaluación del Rendimiento del Modelo

#### 3.1 Contraste de Hipótesis

La prueba T de Welch —seleccionada tras verificar varianzas desiguales con la prueba de Levene ( $p < 0.001$ )— confirmó la hipótesis alternativa con un nivel de confianza superior al 99.9% ( $p \approx 3.5 \times 10^{-16}$ ). Los empleados que renuncian presentan un ingreso mensual promedio de ~\$4.787 USD frente a ~\$6.833 USD de los que permanecen, una diferencia de ~\$2.046 USD estadísticamente significativa.

Justificación de decisiones: se usó la prueba de Levene como verificación previa del supuesto de homocedasticidad antes de aplicar la prueba t, y se eligió la variante T de Welch (`equal_var=False`) por ser más robusta ante heterogeneidad de varianzas. La prueba fue bilateral porque  $H_1$  no especificaba dirección de diferencia.

**Tabla 2.**

*Resultados del Contraste de Hipótesis*

| Elemento              | Valor                                    |
|-----------------------|------------------------------------------|
| Media — Attrition=Yes | ~\$4.787 USD                             |
| Media — Attrition=No  | ~\$6.833 USD                             |
| Estadístico T         | ~-8.37 (T de Welch)                      |
| P-value               | ~ $3.5 \times 10^{-16}$ Se rechaza $H_0$ |

### 3.2 Regresión Lineal Múltiple

El modelo de regresión lineal con las variables TotalWorkingYears, Age y JobLevel como predictores de MonthlyIncome alcanzó un  $R^2 \approx 0.78$  y un RMSE  $\approx$  \$1.960 USD. JobLevel tiene el mayor impacto por salto unitario (~\$2.185 USD/nivel), mientras que TotalWorkingYears aporta ~\$89 USD por año adicional de experiencia.

Justificación de decisiones: las tres variables fueron seleccionadas con base en la teoría del capital humano (Becker, 1964) que predice que el ingreso es función creciente de la experiencia, la edad y el nivel jerárquico. Se utilizó una división 80/20 con random\_state=42 para garantizar la reproducibilidad. El  $R^2$  de 0.78 con solo tres predictores es satisfactorio e indica que no fue necesario agregar regularización (no se detectó sobreajuste).

**Tabla 3.**

*Métricas del Modelo de Regresión Lineal Múltiple*

| Métrica              | Valor               | Interpretación                                      |
|----------------------|---------------------|-----------------------------------------------------|
| <b>R<sup>2</sup></b> | <b>~0.7831</b>      | Explica el 78.3% de la varianza en MonthlyIncome    |
| <b>MSE</b>           | <b>~3.841.200</b>   | Promedio de errores cuadráticos                     |
| <b>RMSE</b>          | <b>~\$1.960 USD</b> | Error promedio de predicción en unidades originales |

### 3.3 Regresión Logística

El modelo de regresión logística (C=1.0, solver=lbfgs) alcanzó un accuracy del ~80% y una sensibilidad del ~74% con umbral de clasificación 0.30. OverTime fue el predictor con mayor impacto positivo sobre la probabilidad de renuncia (coeficiente  $\approx 1.43$ , equivalente a multiplicar los odds por  $e^{1.43} \approx 4.18$ ).

Justificación del umbral 0.30: en gestión de talento, el costo de un falso negativo (empleado que renuncia sin ser detectado) supera ampliamente el costo de un falso positivo (intervención preventiva innecesaria). Se priorizó la sensibilidad sobre la especificidad. Esta decisión fue validada por el contexto de negocio: reemplazar un empleado cuesta entre el 50% y el 200% de su salario anual.

Justificación de la exploración de hiperparámetros: se evaluaron cuatro valores de C (0.01, 0.1, 1.0, 10.0) y tres solvers (lbfgs, liblinear, saga). La combinación C=1.0 con lbfgs ofreció el mejor equilibrio entre sesgo y varianza para este dataset de tamaño moderado.

**Tabla 4.**

*Métricas del Modelo de Regresión Logística (Umbral = 0.30)*

| <b>Métrica</b>             | <b>Valor</b> | <b>Interpretación</b>                                             |
|----------------------------|--------------|-------------------------------------------------------------------|
| <b>Accuracy</b>            | <b>~80%</b>  | Clasifica correctamente ~80% de los empleados                     |
| <b>Sensibilidad</b>        | <b>~74%</b>  | Detecta ~74% de los empleados que renunciarán                     |
| <b>Especificidad</b>       | <b>~81%</b>  | Identifica correctamente ~81% de los que permanecen               |
| <b>Precisión (clase 1)</b> | <b>~43%</b>  | Esperada con desbalance 16.1%<br>sensibilidad es la métrica clave |

## **4. Diseño y Decisiones del Dashboard**

### **4.1 Estructura y Navegación**

El dashboard está organizado en cuatro pestañas temáticas que siguen el orden lógico del análisis estadístico: Dataset; Contraste de Hipótesis; Regresión Lineal; Regresión Logística. Esta estructura narrativa permite al usuario seguir el razonamiento del analista de forma progresiva y coherente.

### **4.2 Tecnologías Utilizadas**

- Dash 2.17: framework principal para la construcción de la interfaz web interactiva con callbacks de Python.
- Plotly 5.22: biblioteca de visualización interactiva para gráficas de barras, boxplots, histogramas, diagramas de dispersión, mapas de calor y gráficas de radar.
- Scikit-learn 1.5: implementación de los modelos de regresión lineal y logística con `train_test_split`.
- Pandas / NumPy / SciPy: carga, transformación de datos y pruebas estadísticas.

### 4.3 Componentes Interactivos

Se implementaron tres elementos de interactividad mediante callbacks de Dash:

- Filtro de departamento (Tab 1): un Dropdown conectado a un histograma de MonthlyIncome que se actualiza en tiempo real según el departamento seleccionado.
- Slider de umbral de clasificación (Tab 4): permite ajustar el umbral de 0.10 a 0.60 y ver simultáneamente cómo cambian la matriz de confusión y la gráfica de radar de métricas.
- Simulador de perfil de riesgo (Tab 4): el usuario ingresa un ingreso mensual, años en la empresa y si trabaja horas extra; el modelo calcula en tiempo real la probabilidad de renuncia y muestra un semáforo de riesgo (bajo / moderado / alto).

### 4.4 Decisiones de Diseño Visual

Se adoptó una paleta de colores oscura (dark mode) con azul profundo (#0F3460) como color institucional, rojo-naranja (#E94560) como color de acento para destacar alertas y métricas clave, y gris azulado (#A8DADC) para textos secundarios. Esta decisión se justifica por la naturaleza analítica del dashboard: el fondo oscuro reduce la fatiga visual en sesiones largas de análisis.

Se usaron cards con bordes redondeados y sombras para separar visualmente las secciones. Los KPIs se presentan en tarjetas métricas en la parte superior de cada pestaña para que el usuario pueda ver los resultados clave de un vistazo antes de explorar las gráficas detalladas.



## 5. Despliegue: GitHub y Binder

### 5.1 Subir el Proyecto a GitHub

A continuación, se describen los pasos para subir el proyecto a un repositorio público de GitHub:

- Paso 1 — Crear una cuenta en GitHub (si no tienes): ir a <https://github.com> y registrarse.
- Paso 2 — Crear un nuevo repositorio público: clic en el botón + "New repository". Asignar un nombre (ej: hr-attribution-dashboard), marcarlo como Public y clic en "Create repository".
- Paso 3 — Instalar Git: descargar desde <https://git-scm.com/downloads> e instalar.
- Paso 4 — Abrir una terminal (cmd o PowerShell) en la carpeta del proyecto y ejecutar:

```
git init  
git add .  
git commit -m "Dashboard inicial HR Attrition"  
git branch -M main  
git remote add origin https://github.com/TU\_USUARIO/TU\_REPOSITORIO.git  
git push -u origin main
```

- Paso 5 — Verificar: ir a [https://github.com/TU\\_USUARIO/TU\\_REPOSITORIO](https://github.com/TU_USUARIO/TU_REPOSITORIO) y confirmar que los archivos app.py, requirements.txt y README.md están visibles.

### 5.2 Obtener el Dashboard en Binder

Binder ([mybinder.org](https://mybinder.org)) es un servicio gratuito que convierte un repositorio de GitHub en un entorno interactivo ejecutable desde el navegador sin necesidad de instalar Python.

Los pasos son:

- Paso 1 — Ir a <https://mybinder.org>
- Paso 2 — En el campo "GitHub repository name or URL", pegar la URL de tu repositorio: [https://github.com/TU\\_USUARIO/TU\\_REPOSITORIO](https://github.com/TU_USUARIO/TU_REPOSITORIO)

- Paso 3 — En el campo "Path to a notebook file (optional)", escribir: /proxy/8050/
- Paso 4 — Hacer clic en "Launch". Binder construirá el entorno (esto puede tomar 2-5 minutos la primera vez).
- Paso 5 — Copiar la URL que genera Binder. Tendrá el formato:  
[https://mybinder.org/v2/gh/TU\\_USUARIO/TU\\_REPOSITORIO/HEAD?urlpath=%2Fproxy%2F8050%2F](https://mybinder.org/v2/gh/TU_USUARIO/TU_REPOSITORIO/HEAD?urlpath=%2Fproxy%2F8050%2F)
- Paso 6 — Pegar ese link en el archivo links.txt del proyecto.

## 6. Conclusiones

La aplicación sistemática de tres técnicas estadísticas —contraste de hipótesis, regresión lineal múltiple y regresión logística— sobre el dataset IBM HR Analytics Employee Attrition demostró que la rotación laboral es un fenómeno predecible y multivariado. El pipeline completo generó conocimiento accionable para el área de recursos humanos:

- Los empleados que renuncian tienen un ingreso mensual significativamente menor (~\$4.787 USD vs ~\$6.833 USD), diferencia confirmada con  $p \approx 3.5 \times 10^{-16}$ .
- El modelo de regresión lineal explica el 78.3% de la varianza salarial con solo tres variables, siendo JobLevel el predictor de mayor impacto unitario.
- La regresión logística identifica al 74% de los empleados en riesgo de renuncia, priorizando la sensibilidad sobre la precisión por el alto costo de los falsos negativos en RRHH.
- El perfil de mayor riesgo es: empleado con bajo ingreso, poca antigüedad y trabajo en horas extra.

El dashboard construido con Dash y Plotly permite a cualquier analista explorar estos hallazgos de forma interactiva, ajustar el umbral de clasificación según el contexto de negocio y simular el riesgo de renuncia de un empleado específico en tiempo real.

## **7. Referencias**

Becker, G. S. (1964). Human capital: A theoretical and empirical analysis. National Bureau of Economic Research.

Hosmer, D. W., & Lemeshow, S. (2000). Applied logistic regression (2.<sup>a</sup> ed.). Wiley-Interscience.

Oehlert, G. (2010). A first course in design and analysis of experiments. University of Minnesota.

pavansubhasht. (2018). IBM HR Analytics Employee Attrition & Performance [Dataset]. Kaggle. <https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset>

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Plotly. (2023). Dash documentation. <https://dash.plotly.com/>

The Turing Way. (2021). Zero to Binder. <https://the-turing-way.netlify.app/communication/binder/zero-to-binder.html>

Riaño Pascagaza, J. A. (2026). Manual integral: Ciencia de datos aplicada a la retención.

Programación para Ciencia de Datos II.